



统计方法与机器学习

第二章 线性回归分析

倪 蕤

Dase@ECNU

目录

1. 多元线性回归 (Multiple Linear Regression)

I. 模型

II. 参数估计

III. 中心化与标准化

IV. 显著性检验

V. 估计与预测

目录

1. 多元线性回归 (Multiple Linear Regression)

I. 模型

II. 参数估计

III. 中心化与标准化

IV. 显著性检验

V. 估计与预测

问题定义

- 线性回归模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

- 线性回归模型中的显著性水平检验：
 - F 检验：用于检验**回归方程**的显著性；
 - t 检验：用于检验**回归系数**的显著性；
- 此外，还需要评估线性回归的**拟合优度**。

F 检验

- 线性回归模型

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

- **检验的本质**：判断自变量 x_1, x_2, \dots, x_p 从整体上对响应变量 y 是否有明显的影响。
- 假设问题

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_p = 0 \text{ vs } H_1: \text{存在 } \beta_j \text{ 不为零, } j = 1, 2, \dots, p.$$

- 当 H_0 为真，则表明响应变量 y 与 x_1, x_2, \dots, x_p 之间的关系采用多元线性回归模型来刻画并不合适的。

F 检验

- 多元线性回归模型的方差分解公式

拟合值 $\hat{y}_i = \mathbf{x}_i^\top \boldsymbol{\beta}$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

记为

残差 $e_i = y_i - \hat{y}_i$

$$SS_T = SS_R + SS_E$$

总偏差平方和

回归平方和

残差平方和

- 提问：如何构造该检验统计量？

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

1. 残差平方和

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1);$$

2. 残差平方和 SS_E 和回归平方和 SS_R 相互独立；

3. 在原假设 H_0 成立下，

$$\frac{SS_R}{\sigma^2} \sim \chi^2(p).$$

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

1. 残差平方和

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1);$$

2. 残差平方和 SS_E 和回归平方和 SS_R 相互独立；

3. 在原假设 H_0 成立下，

$$\frac{SS_R}{\sigma^2} \sim \chi^2(p).$$

F 检验

- 定理2.7的证明

由于残差

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I} - \mathbf{H})\mathbf{y}$$

于是残差平方和为

$$SS_E = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \mathbf{e}^\top \mathbf{e} = \mathbf{y}^\top (\mathbf{I} - \mathbf{H})\mathbf{y}$$

F 检验

- 定理2.7的证明

由于

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

并且 $\mathbf{I} - \mathbf{H}$ 是对称幂等矩阵，其秩 $\text{rank}(\mathbf{I} - \mathbf{H}) = n - (p + 1)$ 。

因此，

$$\frac{SS_E}{\sigma^2} = \frac{\mathbf{y}^\top (\mathbf{I} - \mathbf{H}) \mathbf{y}}{\sigma^2} \sim \chi^2(n - p - 1)$$

注意到，

$$\delta = \frac{(\mathbf{X}\boldsymbol{\beta})^\top (\mathbf{I} - \mathbf{H}) \mathbf{X}\boldsymbol{\beta}}{\sigma^2} = 0$$

知识回顾

设 $\mathbf{x} \sim N_n(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$ 。

如果 \mathbf{C} 是一个对称矩阵
且 $\text{rank}(\mathbf{C}) = r \leq n$ ，
那么

$$\frac{\mathbf{x}^\top \mathbf{C} \mathbf{x}}{\sigma^2} \sim \chi^2(r, \delta)$$

其中，

$$\delta = \frac{\boldsymbol{\mu}^\top \mathbf{C} \boldsymbol{\mu}}{\sigma^2}$$

当且仅当

$$\mathbf{C}^2 = \mathbf{C}$$

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

1. 残差平方和

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1);$$

2. 残差平方和 SS_E 和回归平方和 SS_R 相互独立；

3. 在原假设 H_0 成立下，

$$\frac{SS_R}{\sigma^2} \sim \chi^2(p).$$

F 检验

- 定理2.7的证明

由于回归平方和

$$SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$= \sum_{i=1}^n (\mathbf{x}_i^\top \hat{\boldsymbol{\beta}} - \bar{\mathbf{x}}^\top \hat{\boldsymbol{\beta}})^2$$

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} \rightarrow \begin{matrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{matrix}$$

$$\frac{\partial Q}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \boldsymbol{\beta}) = 0$$

$$\sum_{i=1}^n y_i = \left(\sum_{i=1}^n \mathbf{x}_i \right)^\top \boldsymbol{\beta}$$

F 检验

- 定理2.7的证明

由于回归平方和

$$SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$= \sum_{i=1}^n (x_i^\top \hat{\beta} - \bar{x}^\top \hat{\beta})^2$$

$$= \hat{\beta}^\top \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^\top \hat{\beta}$$

$$= y^\top X(X^\top X)^{-1} A (X^\top X)^{-1} X^\top y$$

$$x_i^\top \hat{\beta} - \bar{x}^\top \hat{\beta} = (x_i - \bar{x})^\top \hat{\beta} = \hat{\beta}^\top (x_i - \bar{x})$$

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

其中

$$A = \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^\top$$

F 检验

- 定理2.7的证明

由于回归平方和

$$SS_R = \mathbf{y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

又因为残差平方和

$$SS_E = \mathbf{y}^\top (\mathbf{I} - \mathbf{H}) \mathbf{y}$$

因此，

SS_E 与 SS_R 独立。

知识回顾

设 $\mathbf{x} \sim N_n(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$ 。

如果 A 和 B 均是对称矩阵，那么

$\mathbf{x}^\top A \mathbf{x}$ 和 $\mathbf{x}^\top B \mathbf{x}$ 独立

当且仅当

$$\mathbf{AB} = \mathbf{0}_{n \times n}$$

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

1. 残差平方和

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1);$$

2. 残差平方和 SS_E 和回归平方和 SS_R 相互独立；

3. 在原假设 H_0 成立下，

$$\frac{SS_R}{\sigma^2} \sim \chi^2(p).$$

F 检验

- 定理2.7的证明

因为

$$\bar{\mathbf{x}}^\top = (\mathbf{1}_n^\top \mathbf{1}_n)^{-1} \mathbf{1}_n^\top \mathbf{X}$$

我们有

$$\begin{aligned}
 \mathbf{A} &= \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top \\
 &= \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top - n \bar{\mathbf{x}} \bar{\mathbf{x}}^\top \\
 &= \mathbf{X}^\top \mathbf{X} - (\mathbf{1}_n^\top \mathbf{1}_n) \mathbf{X}^\top \mathbf{1}_n (\mathbf{1}_n^\top \mathbf{1}_n)^{-1} (\mathbf{1}_n^\top \mathbf{1}_n)^{-1} \mathbf{1}_n^\top \mathbf{X} \\
 &= \mathbf{X}^\top \mathbf{X} - \mathbf{X}^\top \mathbf{1}_n (\mathbf{1}_n^\top \mathbf{1}_n)^{-1} \mathbf{1}_n^\top \mathbf{X} \\
 &= \mathbf{X}^\top (\mathbf{I}_n - \mathbf{H}_{\mathbf{1}_n}) \mathbf{X}
 \end{aligned}$$

F 检验

- 定理2.7的证明

所以

$$\begin{aligned} SS_R &= \mathbf{y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= \mathbf{y}^\top \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \underbrace{(\mathbf{I} - \mathbf{H}_{1_n})}_{\mathbf{H}} \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \mathbf{y} \\ &= \mathbf{y}^\top \mathbf{H} (\mathbf{I} - \mathbf{H}_{1_n}) \mathbf{H} \mathbf{y} \end{aligned}$$

F 检验

- 定理2.7的证明

由于 $X = (\mathbf{1}_n \quad X_o)$ ，因此，注意到

$$\begin{aligned}
 \mathbf{H} \mathbf{H}_{\mathbf{1}_n} &= (\mathbf{1}_n \quad X_o) \begin{pmatrix} n^{-1} + n^{-2} \mathbf{1}_n^\top X_o A_o X_o^\top \mathbf{1}_n & -n^{-1} \mathbf{1}_n^\top X_o A_o \\ -n^{-1} A_o X_o^\top \mathbf{1}_n & A_o \end{pmatrix} \begin{pmatrix} \mathbf{1}_n^\top \\ X_o^\top \end{pmatrix} \mathbf{H}_{\mathbf{1}_n} \\
 &= (n^{-1} \mathbf{1}_n \mathbf{1}_n^\top + n^{-2} \mathbf{1}_n \mathbf{1}_n^\top X_o A_o X_o^\top \mathbf{1}_n \mathbf{1}_n^\top - n^{-1} \mathbf{1}_n \mathbf{1}_n^\top X_o A_o X_o^\top - n^{-1} X_o A_o X_o^\top \mathbf{1}_n \mathbf{1}_n^\top + X_o A_o X_o^\top) \mathbf{H}_{\mathbf{1}_n} \\
 &= (n^{-1} \mathbf{1}_n \mathbf{1}_n^\top + \mathbf{H}_{\mathbf{1}_n} X_o A_o X_o^\top \mathbf{H}_{\mathbf{1}_n} - \mathbf{H}_{\mathbf{1}_n} X_o A_o X_o^\top - X_o A_o X_o^\top \mathbf{H}_{\mathbf{1}_n} + X_o A_o X_o^\top) \mathbf{H}_{\mathbf{1}_n} \\
 &= (n^{-1} \mathbf{1}_n \mathbf{1}_n^\top)^2 = \mathbf{H}_{\mathbf{1}_n}
 \end{aligned}$$

计算提示

$$\mathbf{H}_{\mathbf{1}_n} X_o A_o X_o^\top \mathbf{H}_{\mathbf{1}_n} - \mathbf{H}_{\mathbf{1}_n} X_o A_o X_o^\top - X_o A_o X_o^\top \mathbf{H}_{\mathbf{1}_n} + X_o A_o X_o^\top = (I - \mathbf{H}_{\mathbf{1}_n}) X_o A_o X_o^\top (I - \mathbf{H}_{\mathbf{1}_n})$$

F 检验

- 定理2.7的证明

所以

$$\begin{aligned} SS_R &= \mathbf{y}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{A} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \\ &= \mathbf{y}^\top \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \underbrace{(\mathbf{I} - \mathbf{H}_{1_n})}_{\mathbf{H}} \underbrace{\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \mathbf{y} \\ &= \mathbf{y}^\top \mathbf{H} (\mathbf{I} - \mathbf{H}_{1_n}) \mathbf{H} \mathbf{y} \\ &= \mathbf{y}^\top (\mathbf{H} - \mathbf{H}_{1_n}) \mathbf{y} \end{aligned}$$

F 检验

- 定理2.7的证明

令

$$\mathbf{B} = (\mathbf{H} - \mathbf{H}_{1_n})$$

易证

- \mathbf{B} 是对称矩阵；
- \mathbf{B} 是幂等矩阵；
- $\text{rank}(\mathbf{B}) = \text{tr}(\mathbf{B}) = \text{tr}(\mathbf{H}) - \text{tr}(\mathbf{H}_{1_n}) = (p + 1) - 1 = p.$

F 检验

- 定理2.7的证明

在 H_0 成立时， $\beta_1 = \beta_2 = \dots = \beta_p = 0$ ，有

$$\mathbf{y} \sim N(\beta_0 \mathbf{1}_n, \sigma^2 \mathbf{I}_n)$$

所以，

$$\frac{SS_R}{\sigma^2} = \frac{\mathbf{y}^\top \mathbf{B} \mathbf{y}}{\sigma^2} \sim \chi^2(p)$$

其中，

$$\delta = \frac{(\beta_0 \mathbf{1}_n)^\top \mathbf{B} (\beta_0 \mathbf{1}_n)}{\sigma^2} = \frac{\beta_0^2}{\sigma^2} \mathbf{1}_n^\top \mathbf{B} \mathbf{1}_n = \frac{\beta_0^2}{\sigma^2} \text{tr}(\mathbf{1}_n^\top \mathbf{B} \mathbf{1}_n) = \frac{\beta_0^2}{\sigma^2} \text{tr}(\mathbf{B} \mathbf{1}_n \mathbf{1}_n^\top)$$

$$= \frac{\beta_0^2}{\sigma^2} \text{tr}(n \mathbf{B} \mathbf{H}_{1_n}) = \frac{n \beta_0^2}{\sigma^2} \text{tr}((\mathbf{H} - \mathbf{H}_{1_n}) \mathbf{H}_{1_n}) = 0$$

知识回顾

设 $x \sim N_n(\mu, \sigma^2 \mathbf{I}_n)$ 。

如果 C 是一个对称矩阵
且 $\text{rank}(C) = r \leq n$ ，
那么

$$\frac{x^\top C x}{\sigma^2} \sim \chi^2(r, \delta)$$

其中，

$$\delta = \frac{\mu^\top C \mu}{\sigma^2}$$

当且仅当

$$C^2 = C$$

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

1. 残差平方和

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1);$$

2. 残差平方和 SS_E 和回归平方和 SS_R 相互独立；

3. 在原假设 H_0 成立下，

$$\frac{SS_R}{\sigma^2} \sim \chi^2(p).$$

F 检验

- 检验统计量为

$$F_0 = \frac{SS_R/p}{SS_E/(n-p-1)} \sim F(p, n-p-1)$$

取显著性水平为 α

- **临界值法**

- 如果 $F_0 > F_{1-\alpha}(p, n-p-1)$ ，那么拒绝原假设；反之，接受原假设。

- **p 值法**

- 如果 $p_0 = P(F \geq F_0) < \alpha$ ，那么拒绝原假设；反之，接受原假设。

- 拒绝原假设，认为回归方程时显著的。

F 检验

方差分析表

来源	平方和	自由度	均方	F 值	p 值
回归	SS_R	p	$\frac{SS_R}{p}$	$F_0 = \frac{SS_R/p}{SS_E/(n-p-1)}$	$p_0 = P(F \geq F_0)$
误差	SS_E	$n - p - 1$	$\frac{SS_E}{n - p - 1}$		
总和	SS_T	$n - 1$			

t 检验

- **目的**：需要进一步判断每一个变量是否显著。
- 检验问题

$$H_{0j}: \beta_j = 0, j = 1, 2, \dots, p$$

- 如果拒绝原假设，认为第 j 个特征是显著的；
- 如果接受原假设，认为第 j 个特征是不显著的；

回顾

定理2.5

在多元线性回归模型中， β 的估计为

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

有以下两个重要性质：

- $\hat{\beta}$ 的期望为

$$E(\hat{\beta}) = \beta$$

- $\hat{\beta}$ 的方差-协方差矩阵为

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$$

F 检验

定理2.7 在正态分布假定下，即

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

有

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \sim N(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$$

- 重要结论

$$\hat{\beta}_j \sim N(\beta_j, c_{jj} \sigma^2)$$

其中， c_{jj} 是矩阵 $(\mathbf{X}^\top \mathbf{X})^{-1}$ 第 $(j+1)$ 个对角线元素，称为方差扩大因子。

知识回顾

设随机向量

$$\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$$

服从正态分布 $N(\boldsymbol{\mu}, \Sigma)$ ，
其中

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_p \end{pmatrix}$$

$$\Sigma = \begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{pmatrix}$$

则每一个分量

$$x_j \sim N(\mu_j, \sigma_{jj})$$

t 检验

- 检验统计量为

$$\frac{\hat{\beta}_j}{\sqrt{c_{jj}}\hat{\sigma}}$$

其中，

$$\hat{\sigma}^2 = SS_E / (n - p - 1)$$

- 在 H_0 成立时，

$$t_0 = \frac{\hat{\beta}_j}{\sqrt{c_{jj}}\hat{\sigma}} \sim t(n - p - 1)$$

t 检验

取显著性水平为 α

- **临界值法**

- 如果 $|t_j| > t_{1-\alpha/2}(n - p - 1)$ ，那么拒绝原假设；反之，接受原假设。

- **p 值法**

- 如果 $p_0 = 2P(t \geq |t_j|) < \alpha$ ，那么拒绝原假设；反之，接受原假设。

- 拒绝原假设，认为回归系数时显著的。

复相关系数

- 拟合优度是用于度量回归方程对观测值的拟合程度。
- 定义样本决定系数为

$$R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T}$$

- 可证明：在多元线性回归模型中， $0 \leq R^2 \leq 1$ 。
 - R^2 越接近 1，回归拟合效果越好；
 - R^2 越接近 0，回归拟合效果越差；
- 虽然 R^2 常用于回归任务的评价指标，但是， R^2 并不是严格的显著性检验。

复相关系数

- 称

$$R = \sqrt{R^2}$$

为 y 关于 x_1, x_2, \dots, x_p 的样本复相关系数。

- **样本复相关系数与样本相关系数的比较**

	度量对象	取值范围	用途
样本复相关系数 R	y 和 x_1, x_2, \dots, x_p	$[0,1]$	衡量 x_1, x_2, \dots, x_p 与 y 的线性关系
样本相关系数 r	y 和 x_j	$[-1,1]$	衡量 x_j 与 y 的线性关系

总结

- 回归方程的检验

$$F_0 = \frac{SS_R/p}{SS_E/(n-p-1)} \sim F(p, n-p-1)$$

- 回归系数的检验

$$t_0 = \frac{\hat{\beta}_j}{\sqrt{c_{jj}}\hat{\sigma}} \sim t(n-p-1)$$

- 回归的拟合优度

$$R^2 = \frac{SS_R}{SS_T}$$

目录

1. 多元线性回归 (Multiple Linear Regression)

I. 模型

II. 参数估计

III. 中心化与标准化

IV. 显著性检验

V. 估计与预测

问题定义

- 提问：在确定参数估计 $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)$ 之后，我们可以做些什么？
- 对于一个新数据

$$\boldsymbol{x}_0 = (1, x_{01}, x_{02}, \dots, x_{0p})^\top$$

其所对应的响应变量 y_0 是未知的。

- 自然可以假设 y_0 是一个随机变量。
- 由此衍生出两类问题：
 - 对 y_0 的猜测，统称为**预测**问题；
 - 对 $\mu_0 = E(y_0)$ 的猜测，统称为**估计**问题。

问题定义

- **前提**：参数估计为 $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)$ ，新数据为 $x_0 = (1, x_{01}, x_{02}, \dots, x_{0p})^\top$ 。
- 如果要用一个“点”来猜测 y_0 或 $E(y_0)$ ，一个自然的想法是

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \dots + \hat{\beta}_p x_{0p} = x_0^\top \hat{\beta}$$

- 提问： \hat{y}_0 作为一个猜测，它的效果如何？
- 显然， \hat{y}_0 是 $\hat{\beta}$ 的线性函数。

点预测

定理2.8 在多元线性回归模型中， \hat{y}_0 是 y_0 的无偏预测，即 $E(\hat{y}_0) = E(y_0)$ 。

- **定理2.8的证明**
- 根据定理2.5可知，

$$E(\hat{y}_0) = E(x_0^\top \hat{\beta}) = x_0^\top E(\hat{\beta}) = x_0^\top \beta$$

而

$$y_0 = x_0^\top \beta + \varepsilon_0$$

其中 $E(\varepsilon_0) = 0$ 和 $\text{Var}(\varepsilon_0) = \sigma^2$

所以，

$$E(y_0) = x_0^\top \beta$$

知识回顾

β 的估计为

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

其期望为

$$E(\hat{\beta}) = \beta$$

点预测

- 点预测为

$$\hat{y}_0 = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} = \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

是 $\mathbf{y} = (y_1, y_2, \dots, y_n)^\top$ 的线性函数。

- \hat{y}_0 是线性预测。

定理2.9 设 $\hat{\boldsymbol{\beta}}$ 是 $\boldsymbol{\beta}$ 的最小二乘估计。对于任一 $(p + 1)$ 维常数向量 \mathbf{c} ， $\mathbf{c}^\top \hat{\boldsymbol{\beta}}$ 是 $\mathbf{c}^\top \boldsymbol{\beta}$ 的最小方差无偏估计。

推论

在 y_0 的一切线性无偏预测中， \hat{y}_0 的方差最小。

点预测

- 定理2.9的证明
- 设 $\mathbf{d}^\top \mathbf{y}$ 是 $\mathbf{c}^\top \boldsymbol{\beta}$ 的一个线性无偏估计，即

$$\mathbf{c}^\top \boldsymbol{\beta} = E(\mathbf{d}^\top \mathbf{y}) = E(\mathbf{d}^\top (\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon})) = \mathbf{d}^\top \mathbf{X}\boldsymbol{\beta}$$

于是，

$$\mathbf{c}^\top = \mathbf{d}^\top \mathbf{X}$$

又因为

$$\text{Var}(\mathbf{d}^\top \mathbf{y}) = \sigma^2 \mathbf{d}^\top \mathbf{d}$$

和

$$\text{Var}(\mathbf{c}^\top \widehat{\boldsymbol{\beta}}) = \mathbf{c}^\top \text{Var}(\widehat{\boldsymbol{\beta}}) \mathbf{c} = \sigma^2 \mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c} = \sigma^2 \mathbf{d}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{d}$$

点预测

- 定理2.9的证明

于是

$$\begin{aligned}\text{Var}(\mathbf{d}^\top \mathbf{y}) - \text{Var}(\mathbf{c}^\top \hat{\boldsymbol{\beta}}) &= \sigma^2 \mathbf{d}^\top \mathbf{d} - \sigma^2 \mathbf{d}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{d} \\ &= \sigma^2 \mathbf{d}^\top \mathbf{d} - \sigma^2 \mathbf{d}^\top \mathbf{H} \mathbf{d} \\ &= \sigma^2 \mathbf{d}^\top (\mathbf{I} - \mathbf{H}) \mathbf{d} \geq 0\end{aligned}$$

所以， $\mathbf{c}^\top \hat{\boldsymbol{\beta}}$ 是 $\mathbf{c}^\top \boldsymbol{\beta}$ 的最小方差无偏估计。

点预测

- 从理论分析中，不难看出 \hat{y}_0 是 y_0 一个不错的预测值。
- 在实际中， \hat{y}_0 仍与 y_0 存在偏差。分解一下偏差的构成方式。

$$\begin{aligned}
 & (\hat{y}_0 - y_0)^2 \\
 &= (\hat{y}_0 - E(\hat{y}_0) + E(\hat{y}_0) - E(y_0) + E(y_0) - y_0)^2 \\
 &= (\hat{y}_0 - E(\hat{y}_0))^2 + 2(\hat{y}_0 - E(\hat{y}_0))(E(\hat{y}_0) - E(y_0)) \\
 &\quad + (E(\hat{y}_0) - E(y_0))^2 + 2(E(\hat{y}_0) - E(y_0))(E(y_0) - y_0) \\
 &\quad + (E(y_0) - y_0)^2 + 2(\hat{y}_0 - E(\hat{y}_0))(E(y_0) - y_0) \\
 &= (\hat{y}_0 - E(\hat{y}_0))^2 + 2(\hat{y}_0 - E(\hat{y}_0))(E(\hat{y}_0) - E(y_0)) \\
 &\quad + (E(\hat{y}_0) - E(y_0))^2 + 2(E(\hat{y}_0) - E(y_0))(-\varepsilon_0) \\
 &\quad + \varepsilon_0^2 + 2(\hat{y}_0 - E(\hat{y}_0))(-\varepsilon_0)
 \end{aligned}$$

点预测

- 从理论分析中，不难看出 \hat{y}_0 是 y_0 一个不错的预测值。
- 在实际中， \hat{y}_0 仍与 y_0 存在偏差。分解一下偏差的构成方式。
- 于是有，

$$E(\hat{y}_0 - y_0)^2 = \text{Var}(\hat{y}_0) + \text{Bias}^2(\hat{y}_0) + \text{Var}(\varepsilon_0)$$

区间估计

- 点估计为

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \cdots + \hat{\beta}_p x_{0p} = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}}$$

- 其分布为

$$\hat{y}_0 \sim N(\mathbf{x}_0^\top \boldsymbol{\beta}, \sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0)$$

- 因为 σ^2 是冗余参数，其常见的估计为 $\hat{\sigma}^2 = SS_E / (n - p - 1)$ 。
- 又因为

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1)$$

区间估计

- 枢轴量为

$$\frac{\hat{y}_0 - \mathbf{x}_0^\top \boldsymbol{\beta}}{\hat{\sigma} \sqrt{\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}} \sim t(n - p - 1)$$

- 取置信水平为 $1 - \alpha$ 。
- 于是， $\mu_0 = E(y_0)$ 的 $1 - \alpha$ 置信区间为

$$\hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n - p - 1) \hat{\sigma} \sqrt{\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

区间预测

- 点预测为

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \cdots + \hat{\beta}_p x_{0p} = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}}$$

- 其分布为

$$\hat{y}_0 \sim N(\mathbf{x}_0^\top \hat{\boldsymbol{\beta}}, \sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0)$$

- 而真实值 y_0 的分布为

$$y_0 \sim N(\mathbf{x}_0^\top \boldsymbol{\beta}, \sigma^2)$$

\hat{y}_0 和 y_0 相互独立

- $\hat{y}_0 - y_0$ 的分布为

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2 (1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0))$$

区间预测

- $\hat{y}_0 - y_0$ 的分布为

$$\hat{y}_0 - y_0 \sim N(0, \sigma^2(1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0))$$

- 因为 σ^2 是冗余参数，其常见的估计为 $\hat{\sigma}^2 = SS_E / (n - p - 1)$ 。
- 又因为

$$\frac{SS_E}{\sigma^2} \sim \chi^2(n - p - 1)$$

- 于是有

$$\frac{\hat{y}_0 - y_0}{\hat{\sigma} \sqrt{1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}} \sim t(n - p - 1)$$

区间预测

- 令

$$P\left(c_1 < \frac{\hat{y}_0 - y_0}{\hat{\sigma}\sqrt{1 + \mathbf{x}_0^\top(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{x}_0}} < c_2\right) \geq 1 - \alpha$$

- y_0 的 $1 - \alpha$ 预测区间为

$$\hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n-p-1)\hat{\sigma}\sqrt{1 + \mathbf{x}_0^\top(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{x}_0}$$

总结与思考

- y_0 的点预测

$$\hat{y}_0 = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}}$$

- $\mu_0 = E(y_0)$ 的 $1 - \alpha$ 置信区间为

$$\hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n-p-1)\hat{\sigma} \sqrt{\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$

- y_0 的 $1 - \alpha$ 预测区间为

$$\hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n-p-1)\hat{\sigma} \sqrt{1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0}$$



谢谢